

**聯華神通集團【第23屆育秀盃創意獎】
初賽作品企劃書 (數位應用類)**



參賽編號 (ID)	SA230787	隊伍名稱	AI Picture Detector
作品名稱 (中文)	數位詐騙防治雲端鑑識平台	作品名稱 (英文)	Digital Fraud Prevention Cloud Forensics Platform

數位詐騙防治雲端鑑識平台



第23屆育秀盃創意獎 23th Y.S. AWARDS award.ysed.org.tw

115台北市南港區市民大道八段205號15樓 Tel:02-26516200#7503 ysedaward@gmail.com

一、作品說明

隨著生成式 AI 技術的快速進步，我們已進入一個「眼見不一定為憑」的時代。雖然 AI 極大地提升了生產力，但也帶來了雙面刃效應，尤其在商業及媒體應用現場，專業人士若過度依賴 AI 生成內容，可能導致圖片以假亂真，嚴重擾亂判斷能力。鑑於現有肉眼辨識的侷限性，以及市面上缺乏針對「圖文雙重檢測」且具備「可解釋性」的工具，本作品旨在開發一套高效、精準的 AI 生成檢測系統。我們希望透過科技手段，不僅給出判斷結果，更協助使用者理解 AI 生成的特徵，從而提升大眾的媒體識讀能力，並維護學術誠信與資訊安全。

With the rapid evolution of generative artificial intelligence, we have entered an era where visual evidence is no longer synonymous with truth. While these technologies have drastically enhanced productivity, they have also introduced a complex double-edged sword effect, particularly within news media and commercial sectors where an over-reliance on synthetic content can result in hyper-realistic fabrications that severely distort human judgment. Recognizing the inherent limitations of human perception and the current market's lack of interpretable, dual-verification tools for both text and imagery, this project seeks to develop an advanced AI generation detection system that provides not only definitive diagnostic results but also actionable insights into the specific characteristics of synthetic content to improve media literacy, academic integrity, and information security.

二、創新構想

現今各種AI已經融入我們的生活。AI可以幫助我們做許多事情，其中，有許多人會將生成式AI當成完成工作，抑或是生成圖片的工具。但是過分的依賴生成式AI，讓圖片全部都是由AI完成，並且未經驗證就將其作為圖證、新聞畫面是我們不樂見的，尤其現今大眾並不都具有辨明是非的能力。基於此，我們想開發一前所未有之偵測AI生成程度的系統，不只給出AI生成的可能性，更給出AI生成的特徵，協助民眾辨識圖片的真偽。

第23屆育秀盃創意獎 23th Y.S. AWARDS award.ysed.org.tw

115台北市南港區市民大道八段205號15樓 Tel:02-26516200#7503 ysedaward@gmail.com

三、功能介紹

使用、操作介面如下，分成使用者端以及後台訓練端。

(一)使用者端

1. 可上傳圖片以及文字進行數據處理
2. 比對AI圖庫特徵以及AI生成文字特徵並且根據其進行分析及對比
3. 根據分析結果給予AI可能性百分比及說明描述

(二)後台訓練端

1. 自動化推論流程：系統接收檔案後，自動觸發多模態AI推論引擎，增強、特徵提取與判讀，無需人工介入。
2. 三層式架構部署：採用展示層、應用層、數據層分離的設計，確保系統的高可用性與資安防護。
3. 數據閉環優化：系統具備「模型微調」與「性能評估」機制，能持續收集新數據(如新版 Midjourney 生成圖)進行模型迭代，提升對新型AI生成工具的偵測率。

四、執行方法

(一) 異質數據集建構與特徵工程 (Dataset Construction)

實作首要任務在於建立具備高度泛化能力的訓練樣本庫。

1. 基準數據採集：整合高品質真實影像與多主流生成模型產出之偽造樣本，確保模型能覆蓋不同生成演算法的分布特徵。
2. 特徵域轉換：針對原始影像進行預處理，提取頻域特徵與重建殘差，為後續多模態分析奠定特徵基礎。

(二) 三維複合式鑑識推論引擎 (Multi-modal Inference Engine)


本作品核心技術在於整合三個層級的特徵進行綜合判讀：

1. 微觀頻譜分析：利用 快速傅立葉變換 (FFT) 偵測生成模型在 Upsampling 過程中產生的規律性偽影，捕捉人眼難以辨識的週期性噪點分布。
2. 擴散重建誤差測量 (Diffusion Reconstruction Error, DIRE): 基於「AI 生成影像具有特定收斂規律」之假設，透過擴散模型對輸入影像進行逆向重建。實作上藉由計算原圖與重建圖間的像素級殘差，作為判定是否為生成內容的高維度指標。


3. 語義與幾何邏輯校驗 (Semantic & Geometric Consistency): 導入預訓練之電腦視覺模型進行解剖學結構分析(如手指節點數)與物理光影投射的一致性檢驗, 揪出生成影像在宏觀語義上的邏輯破綻。
- (三) 雲端原生架構與決策融合 (Cloud-Native & Decision Fusion)
- 為了確保系統的高可用性與推論效率, 採以下技術架構部署:
1. 層次化體系架構: 採用展示層 (User UI)、應用層 (FastAPI 推論引擎) 與數據層分離的設計, 提升系統處理高併發請求的能力。
 2. 動態加權融合 (Weighted Ensemble): 根據微觀、重建與邏輯三個維度的信心指標, 透過加權投票機制產出最終鑑定結果, 降低單一模型可能產生的誤報率。
- (四) 可解釋性人工智慧機制 (Explainable AI, XAI)
- 為滿足法庭與媒體鑑識所需之證據力, 實作「可解釋性分析」:
1. 顯著性地圖: 利用 Grad-CAM 技術將模型判斷權重最高的區域轉化為熱點圖 (Heatmap), 直觀標註出影像中可疑的 AI 生成特徵(如異常邊緣或非自然紋理)。
 2. 鑑識報告自動化: 將量化的推論數據轉譯為具備專業參考價值的文字報告, 實現「判斷結果」與「判斷依據」的高度整合。

五、運行結果以及作品圖

- (一) 網站運行狀況: 網頁目前還尚未可以正常連線, 目前只能於後台訓練端訓練模型如圖(二), 而沒有使用者端, 但本研究未來將製作出使用者介面(UI)簡潔直觀、且使用者上傳資料後, 系統能即時反應, 並在頁面上清楚顯示預測結果之網站。
- (二) 模型表現: 經過多次於訓練端之測試, 模型在處理一般狀況(如明顯物理邏輯不符以及顏色對比度明顯差異)時非常穩定, 辨識(或預測)的準確率達到預期目標, 沒有出現嚴重的當機或跑不動的情況。
- (三) 整體成果: 成功整合了網頁訓練端與後台模型, 目前實現了
1. 輸入資料: 上傳圖片檔以及文字檔以供分析。
 2. 產出結果: 給予置信度百分比
 3. 生成報告: 將結果整合為報告並輸出
- (二) 未來展望: 未來希望能將使用者端整合並且實際發佈如圖(三), 以真正協助民眾可辨識出圖文之真假進而不被其所詐騙。



圖(一)系統運行架構圖



圖(二)訓練端實際網頁截圖



圖(三)完成後網站成果示意圖

六、延伸應用場景

透過這個AI模型的訓練，我們期望可以於以下場景使用：

- (一) 法庭：在法庭上，面對一些關鍵的照片證據，可以用這個AI模型判斷這張圖片的真偽性，提供法官判決的參考。
- (二) 媒體：在社群媒體上，常常會有許多的圖片，可能難以分辨真實性，可以透過這個模型判斷圖片真偽，增加媒體釋讀的能力。
- (三) 教學：在學校時，有些作業是老師希望學生使用真實圖片上傳，老師可利用此模型檢測同學是否是使用AI生成圖片。